

独立金标 v3

标注手册

双人独立盲标 · 事件语义、正文事实与 Graph RAG 关系评测

版本：independent-gold-v3-20260826

冻结日期：2026-08-26（Asia/Shanghai）

适用范围：三行业九家公司公开披露，2024-01-03 至 2026-08-04

核心原则	交付给研究员的文件只是待标注输入，不是金标。只有 A/B 独立完成、差异被裁决、结构校验通过并冻结版本后，才可称为独立金标。
------	--

本手册采用 compact reference guide 版式，便于标注时并排查阅。所有判断均用于研究协作与模型评测，不构成投资建议。

目录与执行摘要

顺序	模块	本轮规模	主要产出
1	事件语义	120 条 × 2 人	筛选、假设匹配、方向、强度、直接性
2	正文事实	60 条 × 2 人	正文定位、事实类型、变化方向、数值与发生期
3	Graph RAG 关系	180 对 × 2 人	0-3 级相关性、关系路径可成立性
4	分歧裁决	动态	保留 A/B 原始结果，形成最终裁决标签
5	冻结与评测	1 个版本	契约、样本哈希、指标和审计清单

工作量	每位研究员共 360 个判断单元。建议拆为 3-4 次完成，每次 60-90 分钟；不得为了追求完成率跳过原文核对。
-----	--

研究员收到的文件

- 标注员 A/B 各一份独立工作簿；两份样本相同、顺序不同。
- 本手册；用于定义口径、异常处理、回收和裁决规则。
- 原文链接已逐条写入；固定字段、核心观点和 H1/H2/H3 均自包含在工作簿中。
- 裁决员另收分歧裁决工作簿；标注员不得查看。

1. 目前还缺什么金标

项目已有 59 条单人盲标和 27 条冻结研究员方向样本，但它们不能完整覆盖当前产品。前者无法计算标注者间一致性，后者主要验证方向闭环，且已有正文事实模板仍为空。Graph RAG 已实现关系检索，但尚无独立的真实问题/关系金标。

金标类型	为什么需要	本包是否覆盖	评测用途
------	-------	--------	------

金标类型	为什么需要	本包是否覆盖	评测用途
事件语义双人金标	补齐事件筛选、证券归属、假设匹配、方向、强度	是，120 条全量双标	Precision/Recall、准确率、宏平均 F1、Cohen κ
正文事实金标	检验是否真正读取正文，而非只读标题	是，60 条全量双标	事实抽取 P/R/F1、类型与方向准确率
Graph RAG 相关性金标	比较 text-only、hybrid、graph 三路召回	是，180 个关系对	Recall@K、MRR、NDCG@K、路径正确率
裁决与审计文件	将 A/B 不一致变成可追溯的最终标签	是，工作簿+契约+哈希	金标版本治理与复算
量化结果标签	收益、回撤和基准超额由行情计算	不交给研究员	量化回测；与语义金标分离

不要混用	研究员评的是“证据是否支持投资假设”；量化链路评的是“冻结信号后市场或基本面发生了什么”。后续收益不能反向决定语义标签。
------	--

2. 角色、盲法与执行顺序

角色	可查看	不可查看	责任
标注员 A	A 工作簿、手册、公告原文	B 文件、历史标签、模型输出	逐行独立完成并保留证据
标注员 B	B 工作簿、手册、公告原文	A 文件、历史标签、模型输出	逐行独立完成并保留证据
裁决员	原文、固定字段、A/B 原始结果	收益结果、模型建议	仅裁决差异和低置信样本
数据管理员	母表、契约、回收文件、哈希	无业务裁决权	校验、合并、冻结和发布版本

执行顺序

- 1. 数据管理员分别发送 A、B 工作簿与本手册，并分配匿名研究员 ID。
- 2. A、B 独立完成，过程中不得讨论具体样本或交换文件。
- 3. 回收后先做结构校验：行数、样本 ID、固定列、枚举、必填、时间与重复。
- 4. 自动生成分歧队列；任何核心标签不同、任一方置信度 ≤ 2 、或存在数据问题均进入裁决。
- 5. 裁决完成后冻结 final-gold-v3，生成 SHA-256 清单；之后不得原位改写，只能升版本。

3. 通用判断原则

3.1 先读事实，再判断假设

- 标题只能用于筛选。标题读不出数字、比较基准或事件结果时，必须打开原文。
- 方向是相对 H1/H2/H3，不是股价方向、情绪、评级或交易动作。
- 若同一公告影响多个假设，事件语义表选择最直接、证据最充分的“主要关联假设”；其他关系会在 Graph RAG 关系表逐条评。
- 公开披露无法支持判断时选“信息不足”；不要用常识补齐公告没有给出的事实。

3.2 相关、中性、无关与信息不足

标签	定义	是否进入证据链	典型情形
支持	证据提高该假设成立的可信度	是	交付量/收入/毛利率等核心指标改善且口径清楚
冲突	证据降低该假设成立的可信度	是	核心指标恶化、项目失败、产能减值或现金流明显承压
中性	与假设相关，但方向未定或正负因素抵消	是	仅披露进度，没有结果；好坏因素同时存在

标签	定义	是否进入证据链	典型情形
无关	不改变任何核心假设	否	程式化公告、治理事项或无金额框架协议
信息不足	材料不可达或信息不足，无法作可靠判断	待复核	原文失效、扫描不可读、证券归属不明

高频事件	高频不等于自动无关；但若单条事件没有新增结果、金额、阶段变化或可观测指标，通常不应进入核心证据链。		
------	---	--	--

4. 事件语义任务（120 条）

工作表：事件语义_120。灰色列不可改，浅黄色列由研究员填写。

字段	填写规则	必填/条件
事件摘要	用 1-2 句重述公告中已发生或已披露的事实，不写预测和建议。	必填
事件类别	按业务事实选一类；不是复现公告目录类型。	必填
主要关联假设	H1/H2/H3/无关/信息不足。	必填
影响方向	支持/冲突/中性/无关/信息不足；必须与主要关联假设一致。	必填
影响强度	高=可直接改变核心指标或失效判断；中=显著但需后续；低=弱信号。	必填
直接性	直接=公告事实直接观察假设；间接=需业务因果链推断。	必填
关键证据原文	建议摘录最短充分证据，并保留数值、口径和期间。	相关时必填
判断理由	说明证据如何影响哪条假设；建议 20-200 字。	必填
置信度	1=几乎无法判断；3=合理但有不确定；5=证据直接充分。	必填

字段	填写规则	必填/条件
数据问题	无/原文不可达/正文不可提取/疑似重复/时间不明确/证券归属存疑/其他。	必填

一致性约束

- 主要关联假设=无关 → 影响方向=无关，影响强度/直接性=不适用。
- 主要关联假设=信息不足 → 影响方向=信息不足；在数据问题中说明原因。
- 主要关联假设为 H1/H2/H3 → 方向不得为无关；关键证据原文原则上必填。
- 不得删除、复制或重排样本；不得改公司、代码、日期、标题、链接、核心观点和三条假设。

5. 正文事实任务（60 条）

工作表：正文事实_60。该任务直接补齐当前空白的 body_fact_gold，并检验系统是否能从正文识别数字、比较基准和发生期间。

字段	规则	示例格式
正文定位	页码+段落/表格位置；扫描件可写图片页码。	第 3 页，第 2 段；表 1 第 4 行
正文片段	粘贴最短充分原文，保留上下文、数字、同比/环比和单位。	本月交付 30,350 辆，同比增长 268%
是否存在可抽取事实	是/否/信息不足。标题暗示有数字但正文打不开时选信息不足。	是
事实类型	营业收入同比、销量或交付量同比、毛利率、产能利用率、资本开支、订单金额、其他。	销量或交付量同比
变化方向	上升/下降/持平/无法判断/不适用。	上升
数值上下限	单点数值上下限相同；区间分别填写；未披露留空。	268 / 268

字段	规则	示例格式
单位	填写原文单位，不得擅自换算。	% / 辆 / 亿元
事实发生期	事实对应的经营期间，不是公告披露日。	2025-01
负样本必须保留	治理、程式化和无法提取数字的公告不是“浪费样本”。它们是事实抽取 Precision 的分母，用于测误抽取。	

6. Graph RAG 相关性任务（180 对）

工作表：GraphRAG 相关性_180。每个关系样本由一条冻结投资假设和一份候选公告组成。系统的原排名、文本分数、图分数和旧标签均已隐藏。

等级	定义	检索评测解释
3-直接相关	公告含可直接支持/冲突/观察该假设的事实，证据无需跨越额外业务前提。	高相关，NDCG 增益最高
2-间接相关	公告通过清晰业务因果链影响假设，但需一层解释。	相关，可进入证据链
1-弱相关	同主题或同公司，但对该假设增量信息很弱。	软相关，通常不应排在 Top-1
0-无关	不回答该假设，也不提供有效关系证据。	负样本
9-信息不足	原文不可达或材料不足，无法判断。	从主指标分母剔除并单报

关系路径可成立

- 是：可从该投资假设沿业务变量/指标/事实到公告原文建立不违反时间与语义的路径。
- 否：只有公司或词面重合，无法形成可信业务关系；或候选公告发生在检索截止时间之后。
- 信息不足：原文缺失、扫描不可读或关键主体不清。

时间边界	判断只能使用“检索截止时间”之前已公开的信息。未来披露即使更相关，也不能让当前关系成立。
------	--

7. 分歧、裁决与最终金标

7.1 自动进入裁决的条件

- A/B 的任何核心标签不同：关联假设、方向、强度、直接性、事实类型、事实方向、相关性等级或路径可成立性。
- 任一标注员置信度 ≤ 2 。
- 任一标注员的数据问题不是“无”。
- 证据原文、期间或证券归属存在明显冲突。

7.2 裁决规则

1. 裁决员先看固定字段与原文，独立形成初步判断。
2. 再查看 A/B 结果与理由，确认差异来自口径、证据、时间还是录入错误。
3. 填写裁决结果和可复核理由，不覆盖 A/B 原始内容。
4. 若原文仍无法支持可靠结论，裁决为信息不足并记录数据问题。

7.3 最终冻结条件

门槛	要求
结构	所有样本 ID 唯一，行数不变，固定字段与母表哈希一致
完整性	所有必填项完成；枚举、置信度和时间格式合法
双标	A/B 对全部 360 个判断单元独立覆盖
一致性	报告原始一致率、Cohen κ /加权 κ ；不只报告百分比

门槛	要求
裁决	全部差异和低置信样本完成裁决，保留原始标签
版本	生成版本号、冻结时间、研究员匿名 ID、样本哈希和文件 SHA-256

8. 回收验收与文件命名

标注员回收文件

- annotator_A_completed_研究员 ID_YYYYMMDD.xlsx
- annotator_B_completed_研究员 ID_YYYYMMDD.xlsx
- 不得另存为旧版 .xls，不得拆表、合并单元格、重命名工作表或复制整列。

回收前自检

检查	通过标准
进度页	事件语义 120/120、正文事实 60/60、Graph RAG 180/180，总体 100%
固定列	公司、代码、日期、标题、链接、核心观点、H1/H2/H3 未修改
原文证据	相关样本尽量给出关键证据；正文事实必须给定位和片段
时间	使用 ISO 8601，如 2026-08-27T14:30:00+08:00
独立性	未查看另一标注员文件、既有金标或模型输出

出现问题时	原文打不开或字段疑似错误，不要改固定列。选择“信息不足”，在“数据问题”中标记，并在理由中写明。
-------	--

9. 标注结果将如何被使用

评测对象	主要指标	解释边界
事件筛选	Precision、Recall、F1、无关提醒率	同时保留噪音样本，不能只看准确率
假设与方向	假设匹配率、宏 F1、方向准确率、Cohen K	方向只在共同相关/可评样本上报告，并给分母
正文事实	抽取 P/R/F1、类型/方向准确率、数值区间命中	负样本与不可读样本分开报告
Graph RAG	Recall@1/5/10、MRR、NDCG@K、Top-1 引用、路径正确率	同时报告越权数和未来信息泄漏数
量化模块	收益、超额收益、回撤、换手、覆盖率	不把回测收益解释为语义标签正确率

最终对外报告必须写清：金标版本、样本规模、双标覆盖、裁决比例、可评样本分母、置信区间与已知偏差。不能用单人标签或代理规则结果宣称模型已经达到生产效果门槛。

附录 A：快速决策树

- 1. 原文是否可读、主体是否明确？否 → 信息不足并标记数据问题。
- 2. 公告是否提供新增事实，而非纯流程或重复披露？否 → 通常无关。
- 3. 新增事实是否改变 H1/H2/H3 的可观测指标或可信度？否 → 无关；仅同主题 → Graph 相关性 1。
- 4. 能够明确提高/降低假设可信度？是 → 支持/冲突；不能 → 中性。
- 5. 关系是否直接由公告观察到？是 → 直接；需要清晰因果链 → 间接。
- 6. 最后记录最短充分证据、理由、置信度与数据问题。

附录 B：禁止泄漏字段

标注员文件中不得出现：sampling_category、dataset_split、annotator_a/b_*、candidate_direction、proxy_gold_direction、model_output、retrieval_rank、retrieval_score，以及由现有规则或模型生成的解释。数据管理员只在内部母表保存抽样与版本字段。

附录 C：版本信息

字段	值
包版本	independent-gold-v3-20260826
抽样种子	20260826
事件总体	real_data/dataset/events.csv，共 3,784 条
本轮事件	120 条；样本外 61、样本内 59
覆盖	芯片半导体 39、医药 43、新能源汽车 38
冻结清单	manifest.json（SHA-256）
契约	gold_contract_v3.json